

Spese mediche e fattori di rischio: analisi di regressione del dataset `insurance.csv`

Antonio Verde

Indice

Capitolo 1 — Introduzione e descrizione del dataset	2
1.1 Obiettivo del lavoro	2
1.2 Strategia metodologica generale	3
1.3 Descrizione del dataset originale	4
1.4 Qualità del dataset	5
1.5 Tipologia delle variabili	5
1.6 Adeguatezza del dataset	6
Capitolo 2 — Analisi esplorativa iniziale	6
2.1 Analisi univariata delle variabili numeriche	6
2.2 Analisi univariata delle variabili categoriche	13
2.3 Analisi bivariata rispetto a <code>charges</code>	16
2.4 Confronto visivo tra <code>charges</code> , <code>sqrt(charges)</code> e <code>log(charges)</code>	19
2.5 Scelta a vista della trasformazione della risposta	24
2.6 Sintesi dell'EDA e implicazioni per la modellazione	25
Capitolo 3 — Regressioni semplici e selezione iniziale	26
3.1 Regressioni semplici con un solo predittore	26
3.2 Confronto tra i modelli semplici	29
3.3 Forward selection con AIC/BIC	29
3.4 Interpretazione del modello suggerito dalla selezione	31
3.5 Confronto tra selezione automatica e indicazioni esplorative	31
Capitolo 4 — Modelli con predittori numerici e categorici	31
4.1 e 4.2 Modelli senza e con interazione	32
4.3 Confronto tra modelli con e senza interazione	33
4.4 Discussione delle combinazioni più informative	33
4.5 Scelta delle interazioni eventualmente da mantenere	35

Capitolo 5 — Modello multiplo	36
5.1 Modello additivo	36
5.2 Modello con interazioni motivate	38
5.3 Confronto tra modelli	39
5.4 Confronto ANOVA tra modelli annidati	40
5.5 Verifica sull'utilità di <code>region</code>	40
5.6 Interpretazione dei coefficienti	41
5.7 Valutazione della bontà di adattamento	42
Capitolo 6 — Diagnostica dei residui ed eteroschedasticità	43
6.1 Diagnostica grafica dei residui	43
6.2 Test di normalità e limiti interpretativi	46
6.3 Test di eteroschedasticità	47
6.4 Stima WLS: modello pesato per l'eteroschedasticità	47
Capitolo 7 — Modelli alternativi	50
7.1 Quantile Regression	50
7.2 Confronto degli effetti sui diversi quantili	52
Capitolo 8 — Conclusioni	53
8.1 Sintesi dei risultati principali	53
8.2 Scelta finale del modello	54
8.3 Limiti dell'analisi	54

Capitolo 1 — Introduzione e descrizione del dataset

1.1 Obiettivo del lavoro

La spesa sanitaria individuale varia moltissimo da persona a persona, e capire *quali* fattori la spingono — e di quanto — è una questione centrale sia per le compagnie assicurative sia per le politiche sanitarie. In questo lavoro modelliamo tale spesa (`charges`, importo annuo individuale) a partire da sei caratteristiche demografiche e comportamentali: età (`age`), sesso (`sex`), indice di massa corporea (`bmi`), numero di figli a carico (`children`), status di fumatore (`smoker`) e regione di residenza (`region`).

In termini statistici stiamo stimando una media condizionata, $\mathbb{E}(Y | X)$, dove Y è la spesa e X i predittori. L'obiettivo, però, non è costruire una “scatola nera” che predice il costo: vogliamo un modello **leggibile**, che dica quali fattori spingono la spesa e di quanto.

Lungo tutto il lavoro teniamo separati due obiettivi:

- **esplorativo** — capire la struttura del dato (distribuzioni, relazioni marginali e condizionate) prima di qualsiasi modello;

- **inferenziale** — stimare e interpretare l'associazione tra predittori e risposta, con la giusta cautela sulle ipotesi.

Costruiamo il modello in modo **graduale**: non partiamo da una specifica complessa, ma aggiungiamo struttura solo quando i dati la giustificano. Ogni passo risponde a una domanda precisa:

- che forma ha il dato?
- quali predittori contano da soli?
- quali restano utili a parità degli altri?
- l'inferenza regge quando controlliamo le ipotesi classiche?

Le procedure automatiche e i modelli alternativi sono strumenti di **orientamento e confronto**, non verità definitive.

1.2 Strategia metodologica generale

Il lavoro segue una progressione logica, dal generale al particolare, in cui ogni passo prepara il successivo:

1. **Documentazione del dataset** (questo capitolo);
2. **Analisi esplorativa** univariata e bivariata (Cap. 2);
3. **Scelta della trasformazione** della risposta, a vista, fra `charges`, `sqrt(charges)` e `log(charges)` (Cap. 2.4–2.5);
4. **Regressioni semplici** con un solo predittore (Cap. 3);
5. **Forward selection** con criteri AIC/BIC, come strumento di orientamento (Cap. 3);
6. **Modelli numerico $\times$ categorico**, con e senza interazione (Cap. 4);
7. **Modello multiplo**, additivo e con interazioni motivate (Cap. 5);
8. **Confronto ANOVA** tra modelli annidati (Cap. 5);
9. **Diagnostica dei residui ed eteroschedasticità**, con stima WLS (Cap. 6);
10. **Quantile Regression** per studiare anche la coda alta dei costi (Cap. 7);
11. **Conclusioni** (Cap. 8).

Un principio guida tutto il percorso: **nessuna procedura automatica vale come prova definitiva**. Selezione e confronti tra modelli sono indizi, da integrare con l'interpretazione e con la coerenza rispetto ai dati.

In sintesi: partiamo da una descrizione semplice, accumuliamo evidenza senza anticipare le conclusioni, e arriviamo a una specifica finale che sia buona sui numeri e spiegabile. Per questo il modello principale resta un modello lineare interpretabile, che più avanti stimiamo con pesi WLS per tenere conto dell'eteroschedasticità residua.

1.3 Descrizione del dataset originale

Il dataset è `insurance.csv`, un dataset didattico molto noto sui costi assicurativi sanitari statunitensi, introdotto da Brett Lantz nel libro *Machine Learning with R* (Packt Publishing), nel capitolo dedicato alla regressione, e in seguito ampiamente diffuso su Kaggle. Ogni riga è un assicurato; `charges` è il costo sanitario annuo individuale **addebitato tramite l'assicurazione** (in dollari): la spesa medica sostenuta per l'assicurato e coperta dalla compagnia, non il premio pagato né la quota a suo carico.

In totale abbiamo **1338 osservazioni** e **7 variabili**. La struttura grezza è questa:

```
# Struttura del dataset originale (prima di qualsiasi intervento), in forma
# tabellare: per ogni variabile il tipo, i livelli (se fattore) o l'intervallo
# min-max (se numerica). Più leggibile dell'output grezzo di str().
tipo_var <- function(x) {
  if (is.factor(x))      sprintf("Fattore (%d livelli)", nlevels(x))
  else if (is.integer(x)) "Intero"
  else                   "Numerico"
}

descr_var <- function(x) {
  if (is.factor(x)) {
    paste(levels(x), collapse = ", ")
  } else {
    rng <- round(range(x), 2)
    paste0("da ", format(rng[1], big.mark = ",", trim = TRUE),
          " a ", format(rng[2], big.mark = ",", trim = TRUE))
  }
}

tibble(
  Variabile      = names(ins_orig),
  Tipo           = vapply(ins_orig, tipo_var, character(1)),
  `Livelli / Intervallo` = vapply(ins_orig, descr_var, character(1))
) %>%
knitr::kable(
  align = c("l", "l", "l"),
  caption = "Struttura del dataset originale: 1338 osservazioni e 7 variabili (livelli per i
  ↪ fattori, intervallo min-max per le numeriche).")
)
```

Tabella 1: Struttura del dataset originale: 1338 osservazioni e 7 variabili (livelli per i fattori, intervallo min-max per le numeriche).

Variabile	Tipo	Livelli / Intervallo
age	Intero	da 18 a 64
sex	Fattore (2 livelli)	female, male
bmi	Numerico	da 15.96 a 53.13

Variabile	Tipo	Livelli / Intervallo
children	Intero	da 0 a 5
smoker	Fattore (2 livelli)	no, yes
region	Fattore (4 livelli)	northeast, northwest, southeast, southwest
charges	Numerico	da 1,121.87 a 63,770.43

1.4 Qualità del dataset

Prima di lavorare sui dati ne controlliamo la qualità, a partire dai valori mancanti.

```
# Valori mancanti per colonna.
colSums(is.na(ins_orig))
```

```
      age      sex      bmi children  smoker    region  charges
      0        0        0         0        0         0         0
```

Non ci sono **valori mancanti** (zero su ogni colonna): non serve imputare né escludere osservazioni. Usiamo quindi il dataset nella sua forma originale, con **1338 osservazioni**.

```
# Dataset di analisi: numero di osservazioni.
nrow(ins)
```

```
[1] 1338
```

Tutte le analisi che seguono usano questo dataset (`ins`, 1338 osservazioni).

1.5 Tipologia delle variabili

Le sette variabili hanno natura e ruolo diversi nell'analisi, riassunti qui sotto.

Variabile	Ruolo	Tipo	Note
charges	risposta	numerica continua	costo sanitario annuo (USD), > 0
age	predittore	numerica (discreta in anni)	18–64, trattata come continua
bmi	predittore	numerica continua	indice di massa corporea

Variabile	Ruolo	Tipo	Note
children	predittore	numerica discreta (conteggio)	0–5; trattata come numerica
sex	predittore	categorica	2 livelli: female , male
smoker	predittore	categorica	2 livelli: no (riferimento), yes
region	predittore	categorica	4 livelli: northeast , northwest , southeast , southwest

Le variabili qualitative sono convertite in **fattori**: in fase di stima R le codifica con $k - 1$ variabili indicatrici, e un livello finisce nell'intercetta come riferimento. Per **smoker** abbiamo messo **no** come riferimento, così il coefficiente di **yes** si legge direttamente come **extra-costo del fumo**.

1.6 Adeguatezza del dataset

Nel complesso il dataset è **adatto a un'analisi di regressione**: risposta continua e positiva, un buon mix di predittori numerici e categorici, livelli categorici abbastanza numerosi per stime affidabili e nessun valore mancante.

Capitolo 2 — Analisi esplorativa iniziale

L'analisi esplorativa precede e orienta la modellazione. In questa fase non si assume alcuna struttura: si osservano le distribuzioni delle variabili e le loro relazioni con la risposta, traducendo le regolarità osservate in ipotesi di lavoro da verificare nei capitoli successivi.

2.1 Analisi univariata delle variabili numeriche

Si parte dalle quattro variabili numeriche (**age**, **bmi**, **children**, **charges**). La tabella seguente ne riassume le statistiche di sintesi; subito dopo ne osserviamo la forma distribuzionale con istogrammi e boxplot.

```

# Statistiche di sintesi (una riga per variabile).
desc_stats <- ins %>%
  select(age, bmi, children, charges) %>%
  pivot_longer(everything(), names_to = "Variabile", values_to = "v") %>%
  group_by(Variabile) %>%
  summarise(
    Media    = mean(v),
    Mediana  = median(v),
    SD       = sd(v),
    Min      = min(v),
    Q1       = quantile(v, 0.25),
    Q3       = quantile(v, 0.75),
    Max      = max(v),
    .groups  = "drop"
  )

# Trasponiamo (statistiche sulle righe, variabili sulle colonne): poche colonne,
# ciascuna su una scala omogenea, e separatore delle migliaia per charges,
# così la tabella è molto più leggibile.
desc_stats %>%
  pivot_longer(-Variabile, names_to = "Statistica", values_to = "Valore") %>%
  pivot_wider(names_from = Variabile, values_from = Valore) %>%
  select(Statistica, age, bmi, children, charges) %>%
  knitr::kable(digits = 2,
    format.args = list(big.mark = ",", scientific = FALSE),
    align = c("l", "r", "r", "r", "r"),
    caption = "Statistiche descrittive delle variabili numeriche (dataset di
    ↪ analisi, n = 1338).")

```

Tabella 2: Statistiche descrittive delle variabili numeriche (dataset di analisi, n = 1338).

Statistica	age	bmi	children	charges
Media	39.21	30.66	1.09	13,270.42
Mediana	39.00	30.40	1.00	9,382.03
SD	14.05	6.10	1.21	12,110.01
Min	18.00	15.96	0.00	1,121.87
Q1	27.00	26.30	0.00	4,740.29
Q3	51.00	34.69	2.00	16,639.91
Max	64.00	53.13	5.00	63,770.43

```

# Un istogramma per variabile, come figura singola a piena dimensione.
for (v in c("age", "bmi", "children", "charges")) {
  print(
    ggplot(ins, aes(x = .data[[v]])) +
      geom_histogram(bins = 30, fill = num_cols[[v]], color = "white", linewidth = 0.2) +
      labs(title = paste("Distribuzione di", v), x = v, y = "frequenza assoluta") +
      theme_minimal()
  )
}

```

```
)  
}
```




Figura 1: Distribuzione di age




Figura 2: Distribuzione di bmi




Figura 3: Distribuzione di children




Figura 4: Distribuzione di charges

```
# Un boxplot per variabile (scala originale), come figura singola.
for (v in c("age", "bmi", "children", "charges")) {
  print(
    ggplot(ins, aes(y = .data[[v]])) +
    geom_boxplot(fill = num_cols[[v]], alpha = 0.75, outlier.color = "#E76F51",
      ↪ outlier.alpha = 0.6) +
    labs(title = paste("Boxplot di", v), y = v) +
    theme_minimal()
  )
}
```




Figura 5: Boxplot di age




Figura 6: Boxplot di bmi




Figura 7: Boxplot di children




Figura 8: Boxplot di charges

Le distribuzioni suggeriscono alcune indicazioni per la modellazione. La risposta **charges**

è **fortemente asimmetrica a destra**: media (≈ 13.279 USD) nettamente superiore alla mediana (≈ 9.386 USD) e una coda di costi elevati che il boxplot evidenzia come una nuvola di punti oltre il baffo superiore. Questa asimmetria — che il Capitolo 2.4 affronterà scegliendo una trasformazione della risposta — è il tratto distribuzionale più rilevante per il seguito. La variabile **age** è approssimativamente uniforme nell'intervallo 18–64; **bmi** è quasi simmetrica e centrata intorno a 30.7; **children** è una variabile di conteggio concentrata sui valori bassi (mediana 1). I punti “estremi” di **charges** non vanno letti come errori da rimuovere: rappresentano soggetti ad alto costo (eventi clinici importanti) coerenti con la natura del fenomeno.

2.2 Analisi univariata delle variabili categoriche

Per le tre variabili categoriche si osservano le frequenze assolute e relative.

```
freq_tab <- function(x, nome) {
  t <- table(x)
  data.frame(
    Variabile = nome,
    Livello   = names(t),
    n         = as.integer(t),
    Perc      = round(100 * as.numeric(prop.table(t)), 1)
  )
}

bind_rows(
  freq_tab(ins$sex,      "sex"),
  freq_tab(ins$smoker,   "smoker"),
  freq_tab(ins$region,   "region")
) %>%
  knitr::kable(caption = "Frequenze assolute e relative delle variabili categoriche (n =
  ↪ 1338).")
```

Tabella 3: Frequenze assolute e relative delle variabili categoriche (n = 1338).

Variabile	Livello	n	Perc
sex	female	662	49.5
sex	male	676	50.5
smoker	no	1064	79.5
smoker	yes	274	20.5
region	northeast	324	24.2
region	northwest	325	24.3
region	southeast	364	27.2
region	southwest	325	24.3

```
# Un grafico a barre per ciascuna categoria, come figura singola.
for (v in c("sex", "smoker", "region")) {
  print(
    ggplot(ins, aes(x = .data[[v]])) +
    geom_bar(aes(fill = .data[[v]]), color = "white", linewidth = 0.2, show.legend = FALSE)
    ↪ +
    scale_fill_manual(values = cat_cols) +
    labs(title = paste("Frequenze assolute di", v), x = v, y = "n") +
    theme_minimal()
  )
}
```




Figura 9: Frequenze di sex




Figura 10: Frequenze di smoker




Figura 11: Frequenze di region

Il quadro è il seguente. **sex** è quasi paritaria (circa 49.5% femmine, 50.5% maschi). **region** è ben bilanciata fra le quattro aree (ciascuna intorno al 24–27%). **smoker** è invece **sbilanciata**: i fumatori sono circa il 20% del campione. Lo sbilanciamento non è di per sé problematico — la numerosità assoluta dei fumatori (274) è ampiamente sufficiente per stimare in modo affidabile il relativo effetto — ma va tenuto presente nell'interpretazione.

2.3 Analisi bivariata rispetto a charges

Si osserva ora come la risposta varia rispetto a ciascun predittore. Per i predittori numerici si usano scatterplot; per i categorici, boxplot. La scelta di **stratificare per smoker** alcuni scatterplot non è solo grafica: serve a capire se l'effetto di un predittore numerico è omogeneo fra fumatori e non fumatori (stessa pendenza) oppure no.

```
# Un boxplot di charges per ciascun fattore categorico, come figura singola.
for (v in c("sex", "smoker", "region")) {
  print(
    ggplot(ins, aes(x = .data[[v]], y = charges, fill = .data[[v]])) +
    geom_boxplot(alpha = 0.7, show.legend = FALSE) +
    scale_fill_manual(values = cat_cols) +
    labs(title = paste("charges vs", v), x = v, y = "charges") +
    theme_minimal()
  )
}
```




Figura 12: charges per sex




Figura 13: charges per smoker




Figura 14: charges per region

```
ggplot(ins, aes(x = age, y = charges, color = smoker)) +
  geom_point(alpha = 0.5) +
  geom_smooth(method = "lm", se = FALSE) +
  scale_color_manual(values = smoker_cols) +
  labs(title = "charges vs age, per smoker",
       subtitle = "Rette simili a prima vista: l'interazione age:smoker sarà verificata nel
       ↪ Cap. 4") +
  theme_minimal()
```




Figura 15: charges vs age, stratificato per smoker. A prima vista le rette dei due gruppi sembrano abbastanza vicine; la dipendenza dell'effetto di age da smoker sarà verificata formalmente nel Cap. 4.

```
ggplot(ins, aes(x = bmi, y = charges, color = smoker)) +
  geom_point(alpha = 0.5) +
  geom_smooth(method = "lm", se = FALSE) +
  scale_color_manual(values = smoker_cols) +
  labs(title = "charges vs bmi, per smoker",
       subtitle = "Pendence diverse fra i gruppi: possibile interazione bmi:smoker") +
  theme_minimal()
```




Figura 16: charges vs bmi, stratificato per smoker. La pendenza appare quasi piatta per i non fumatori e ripida per i fumatori: l'effetto di bmi sembra dipendere dallo status di fumatore (possibile interazione, da verificare).

Le evidenze bivariate suggeriscono alcune ipotesi di lavoro. Il fattore **smoker** è quello che separa più nettamente la distribuzione di **charges**: la differenza fra fumatori e non fumatori appare molto più ampia di quella prodotta dagli altri fattori. **sex** e **region** mostrano differenze più contenute rispetto alla variabilità interna ai gruppi. Sul piano delle relazioni numeriche, lo scatterplot di **bmi** mostra una pendenza quasi piatta per i non fumatori e più ripida per i fumatori: ciò **suggerisce** una possibile interazione **bmi:smoker**. Lo scatterplot di **age**, invece, mostra rette *a prima vista* più vicine fra i due gruppi; ma l'impressione visiva non è una prova, e nel Capitolo 4 verificheremo formalmente se anche **age** interagisca con **smoker**. Tutte queste restano, per ora, **ipotesi esplorative** da sottoporre a verifica nei Capitoli 4 e 5, non assunzioni a priori.

2.4 Confronto visivo tra charges, sqrt(charges) e log(charges)

La forte asimmetria di **charges** rende opportuno valutare una trasformazione della risposta. Costruiamo quindi due trasformazioni candidate, $\text{sqrt_charges} = \sqrt{\text{charges}}$ e $\text{log_charges} = \log(\text{charges})$, e le confrontiamo **a vista** con la scala originale. Il criterio è puramente distribuzionale — quale scala rende la risposta meno asimmetrica e più gestibile — e si basa sull'osservazione delle distribuzioni, **non** sulla diagnostica dei residui di un modello (che interverrà solo più avanti, su tutt'altra questione).

```
# Una densità per ciascuna scala della risposta, come figura singola.
scale_list <- list("charges"      = ins$charges,
                  "sqrt(charges)" = ins$sqrt_charges,
                  "log(charges)"  = ins$log_charges)
for (nm in names(scale_list)) {
  print(
    ggplot(data.frame(v = scale_list[[nm]]), aes(x = v)) +
    geom_density(fill = "#457B9D", color = "#1D3557", alpha = 0.55, linewidth = 0.7) +
    labs(title = paste("Densità di", nm), x = nm, y = "densità") +
    theme_minimal()
  )
}
```




Figura 17: Densità di charges




Figura 18: Densità di $\sqrt{\text{charges}}$




Figura 19: Densità di $\log(\text{charges})$

```
# Un boxplot per ciascuna scala della risposta, come figura singola.
scale_list <- list("charges"      = ins$charges,
                  "sqrt(charges)" = ins$sqrt_charges,
                  "log(charges)"  = ins$log_charges)
for (nm in names(scale_list)) {
  print(
    ggplot(data.frame(v = scale_list[[nm]]), aes(y = v)) +
    geom_boxplot(fill = "#457B9D", alpha = 0.75, outlier.color = "#E76F51", outlier.alpha =
      ↪ 0.6) +
    labs(title = paste("Boxplot di", nm), y = nm) +
    theme_minimal()
  )
}
```




Figura 20: Boxplot di charges




Figura 21: Boxplot di $\sqrt{\text{charges}}$




Figura 22: Boxplot di $\log(\text{charges})$

A supporto della lettura visiva, riportiamo anche l'indice di **asimmetria (skewness)** nelle tre

scales, che quantifica ciò che i grafici mostrano.

```
tibble(
  Scala = c("charges", "sqrt(charges)", "log(charges)"),
  Skewness = round(c(skewness(ins$charges),
                     skewness(ins$sqrt_charges),
                     skewness(ins$log_charges)), 3)
) %>%
  knitr::kable(caption = "Asimmetria (skewness) della risposta nelle tre scale.")
```

Tabella 4: Asimmetria (skewness) della risposta nelle tre scale.

Scala	Skewness
charges	1.514
sqrt(charges)	0.795
log(charges)	-0.090

2.5 Scelta a vista della trasformazione della risposta

Il confronto mette in evidenza un compromesso. Sulla scala originale **charges** è fortemente asimmetrica a destra (skewness ≈ 1.51). La radice quadrata **riduce** l'asimmetria pur senza eliminarla del tutto (skewness ≈ 0.80 , ancora positiva); il logaritmo la spinge oltre, fino a una distribuzione **quasi simmetrica** (skewness ≈ -0.09). Sul solo criterio della simmetria, quindi, il logaritmo arriva più lontano.

La simmetria, però, non è l'unico criterio che conta: ogni trasformazione **guadagna su alcuni aspetti e soffre su altri**. La tabella seguente li mette a confronto.

Criterio	log(charges)	sqrt(charges)
Simmetria della risposta	guadagna — skewness ≈ -0.09 , quasi normale	soffre — skewness ≈ 0.80 , coda destra residua
Costi elevati (la coda)	soffre — comprime molto i valori alti, appiattendolo proprio la parte di spesa più rilevante	guadagna — li comprime con meno forza, conserva le distanze fra costi bassi e alti
Vicinanza alla scala originale	soffre — scala logaritmica, lontana dai dollari	guadagna — resta vicina alla scala in dollari
Interpretazione dei coefficienti	guadagna — variazioni percentuali ($\exp(\beta)$)	soffre — in unità di $\sqrt{\text{charges}}$, traducibili in dollari solo localmente

Criterio	<code>log(charges)</code>	<code>sqrt(charges)</code>
Varianza degli errori (anticipo Cap. 6)	soffre — eteroschedasticità marcata	guadagna — eteroschedasticità più contenuta

Il punto critico, per dati di spesa sanitaria, è la **coda dei costi elevati**: in ottica assicurativa è la componente che pesa di più, e il logaritmo la comprime troppo, appiattendone differenze che invece contano. La radice quadrata, più delicata, attenua l'asimmetria senza schiacciare i valori alti e resta più vicina alla scala in dollari. Per questo scegliamo `sqrt(charges)` come scala della risposta: accettiamo una simmetria meno marcata in cambio di una rappresentazione più fedele dei costi alti e di una maggiore leggibilità in termini monetari.

D'ora in avanti la risposta sarà quindi

$$y_i = \text{sqrt_charges}_i = \sqrt{\text{charges}_i}.$$

Questa scelta non “risolve” automaticamente tutti i problemi del modello lineare: la diagnostica dei residui andrà comunque verificata dopo la stima. Serve però a mettere la risposta su una scala più regolare, senza comprimere eccessivamente i costi elevati. Sulla scala radice un coefficiente β_j non si legge come variazione percentuale, ma come variazione di $\sqrt{\text{charges}}$; per riportarlo in modo approssimato alla scala originale si usa $\Delta \text{charges} \approx 2\sqrt{\text{charges}} \cdot \beta_j$, quindi lo stesso coefficiente vale più dollari quando il costo di partenza è alto.

2.6 Sintesi dell'EDA e implicazioni per la modellazione

Si raccolgono le indicazioni emerse, da intendere come **ipotesi di lavoro** e non come conclusioni:

1. La risposta `charges` è fortemente asimmetrica; il confronto fra le tre scale porta a scegliere `sqrt(charges)` come risposta, scala che attenua l'asimmetria senza comprimere troppo i costi elevati.
2. `smoker` appare il fattore che separa più nettamente i costi: sarà plausibilmente un predittore centrale.
3. L'analisi bivariata suggerisce che l'effetto di `age` è tendenzialmente additivo, mentre quello di `bmi` potrebbe dipendere dallo status di fumatore (possibile interazione `bmi:smoker`), da **verificare** in fase di modellazione.
4. `sex` e `region` mostrano effetti marginali contenuti: la loro utilità andrà valutata con le regressioni e la selezione.

Queste indicazioni guideranno la costruzione graduale del modello nei capitoli successivi, a partire dalle regressioni semplici.

Capitolo 3 — Regressioni semplici e selezione iniziale

Dopo aver documentato il dataset e svolto l'analisi esplorativa, iniziamo la modellazione dal passo più semplice possibile: una regressione per ogni predittore preso singolarmente. Solo dopo introdurremo una procedura di selezione. La risposta è $y = \text{sqrt_charges}$, scelta nel Capitolo 2.

3.1 Regressioni semplici con un solo predittore

Stimiamo sei modelli, ciascuno con un solo predittore, e ne confrontiamo la capacità esplicativa con R^2 . A questo stadio R^2 è la misura naturale: R^2 aggiustato serve a confrontare modelli di complessità diversa — penalizzando il numero di parametri — e lo introdurremo più avanti, quando confronteremo modelli con un numero diverso di termini (Cap. 4 e 5).

```
preds <- c("age", "bmi", "children", "smoker", "sex", "region")
tab_simple <- do.call(rbind, lapply(preds, function(p) {
  m <- lm(as.formula(paste("sqrt_charges ~", p)), data = ins)
  data.frame(Predittore = p,
             R2 = round(summary(m)$r.squared, 3))
}))
tab_simple <- tab_simple[order(-tab_simple$R2), ]
knitr::kable(tab_simple, row.names = FALSE,
             caption = "Regressioni semplici: una variabile alla volta (y = sqrt_charges).")
```

Tabella 5: Regressioni semplici: una variabile alla volta ($y = \text{sqrt_charges}$).

Predittore	R2
smoker	0.572
age	0.169
bmi	0.028
children	0.011
region	0.004
sex	0.001

Visualizziamo le regressioni semplici più informative. Non riportiamo i grafici di **sex** e **region** perché, dalla tabella, hanno R^2 quasi nullo: mostrarli appesantirebbe il report senza aggiungere una lettura sostanziale.

```
simple_plot_vars <- c("smoker", "age", "bmi", "children")
for (v in simple_plot_vars) {
  if (is.numeric(ins[[v]])) {
    print(
```

```

ggplot(ins, aes(x = .data[[v]], y = sqrt_charges)) +
  geom_point(color = num_cols[[v]], alpha = 0.35) +
  geom_smooth(method = "lm", se = TRUE, color = "#1D3557", fill = "#A8DADC", linewidth =
    ↪ 1) +
  labs(title = paste("Regressione semplice:", v),
        x = v, y = "sqrt(charges)") +
  theme_minimal()
)
} else {
  print(
    ggplot(ins, aes(x = .data[[v]], y = sqrt_charges, fill = .data[[v]])) +
    geom_boxplot(alpha = 0.75, show.legend = FALSE, outlier.alpha = 0.35) +
    stat_summary(fun = mean, geom = "point", shape = 23, size = 3,
      fill = "white", color = "#1D3557") +
    scale_fill_manual(values = cat_cols) +
    labs(title = paste("Regressione semplice:", v),
          subtitle = "Il punto bianco indica la media del gruppo",
          x = v, y = "sqrt(charges)") +
    theme_minimal()
  )
}
}

```




Figura 23: Regressione semplice: smoker




Figura 24: Regressione semplice: age




Figura 25: Regressione semplice: bmi




Figura 26: Regressione semplice: children

3.2 Confronto tra i modelli semplici

La gerarchia è netta. Il predittore di gran lunga più esplicativo, da solo, è **smoker**: spiega circa il **57%** della varianza di **sqrt_charges** ($R^2 \approx 0.572$). Segue **age** ($R^2 \approx 0.169$). Gli altri predittori, presi singolarmente, spiegano poco: **bmi** resta sotto il 3% e **children** intorno all'1%, mentre **sex** e **region** sono praticamente irrilevanti sul piano marginale ($R^2 \approx 0$).

Le regressioni semplici fotografano l'effetto di ciascun predittore preso da solo, ma non vanno lette come misura definitiva di importanza: quando una variabile domina la struttura della risposta, come accade per **smoker**, il contributo di ciascun predittore va poi valutato *a parità degli altri*, cosa che faremo con la selezione e con il modello multiplo.

3.3 Forward selection con AIC/BIC

Introduciamo ora una **forward selection**: partendo dal modello nullo (solo intercetta), si aggiunge a ogni passo la variabile che migliora di più il criterio, fermandosi quando nessuna aggiunta lo migliora. La procedura considera solo gli effetti principali; quindi non può scoprire da sola le interazioni, che verranno valutate nel capitolo successivo.

I due criteri usati sono AIC e BIC:

$$\text{AIC} = -2\log L(\hat{\theta}) + 2p,$$

$$\text{BIC} = -2\log L(\hat{\theta}) + p\log(n),$$

dove $L(\hat{\theta})$ è la verosimiglianza massimizzata, p è il numero di parametri e n è la dimensione campionaria. Il BIC penalizza più severamente i modelli complessi perché, con $n = 1338$, $\log(n)$ è maggiore di 2. La risposta alla domanda metodologica è sì: nel modello lineare AIC e BIC sono calcolati a partire dalla **verosimiglianza gaussiana**, quindi si appoggiano tecnicamente all'ipotesi di normalità degli errori. Per questo li useremo come **criteri relativi di confronto**, non come test definitivi sulla correttezza del modello.

```

null <- lm(sqrt_charges ~ 1, data = ins) # modello nullo
full <- lm(sqrt_charges ~ age + sex + bmi + children + smoker + region, # modello massimo
           data = ins)

fwd_aic <- MASS::stepAIC(null, scope = list(lower = null, upper = full),
                        direction = "forward", k = 2, trace = FALSE)
fwd_bic <- MASS::stepAIC(null, scope = list(lower = null, upper = full),
                        direction = "forward", k = log(nrow(ins)), trace = FALSE)

cat("Forward AIC:\n"); print(formula(fwd_aic))

```

Forward AIC:

```
sqrt_charges ~ smoker + age + bmi + children + region + sex
```

```
cat("Forward BIC:\n"); print(formula(fwd_bic))
```

Forward BIC:

```
sqrt_charges ~ smoker + age + bmi + children
```

I due criteri **non concordano**. L'AIC trattiene tutti e sei gli effetti principali; il BIC, più parsimonioso, si ferma a **smoker + age + bmi + children**, scartando **sex** e **region**. L'ordine di ingresso è coerente con le regressioni semplici — entrano subito **smoker** e **age**, seguiti da **bmi** e **children**. La divergenza è essa stessa un'informazione: **sex** e **region** sono predittori **deboli** su questa scala, abbastanza utili per l'AIC ma non per il BIC. Sulla loro reale utilità torniamo nel modello completo (Cap. 5).

Non affianchiamo la statistica di **Mallows** C_p perché, in questo contesto, aggiungerebbe un terzo criterio molto vicino per funzione: anche C_p confronta adattamento e complessità

nei modelli lineari. Usarlo insieme ad AIC e BIC renderebbe la selezione più pesante senza aggiungere una decisione sostanzialmente diversa. La scelta è quindi di tenere **AIC/BIC**: AIC come criterio meno severo, BIC come criterio più parsimonioso. La concordanza fra i due sarà letta come un segnale utile, non come una prova formale.

3.4 Interpretazione del modello suggerito dalla selezione

La selezione non produce un verdetto unico: l'AIC indica il modello additivo completo $\text{sqrt_charges} \sim \text{age} + \text{sex} + \text{bmi} + \text{children} + \text{smoker} + \text{region}$, mentre il BIC preferisce una versione più corta, senza **sex** e **region**. È importante leggere questo risultato per quello che è: una procedura di selezione **non dimostra** che un modello sia “quello vero”, ma indica quali predittori hanno un contributo più stabile. La selezione, inoltre, è stata condotta solo sugli effetti principali: nulla dice ancora sulle **interazioni**, che affronteremo nel Capitolo 4.

Perché allora teniamo tutti i regressori, anche quelli che il BIC scarta? Per tre ragioni semplici. Primo, i due criteri non concordano: l'AIC li mantiene, quindi non c'è un verdetto netto a favore dell'esclusione. Secondo, AIC e BIC sono strumenti di **orientamento**, non prove definitive: “scartato dal BIC” non significa “inutile”, ma solo “non abbastanza forte per il criterio più severo”. Terzo, **sex** e **region** sono variabili demografiche che in ambito assicurativo ha senso tenere sotto osservazione. La loro utilità reale, comunque, non la decidiamo qui: la verifichiamo *a parità degli altri predittori* nel modello completo (Cap. 5), che è il test che conta davvero.

3.5 Confronto tra selezione automatica e indicazioni esplorative

La selezione è coerente con l'EDA sui predittori forti: **smoker** e **age** emergono subito, seguiti da **bmi** e **children**. **sex** e **region**, invece, restano deboli e vengono trattenuti solo dall'AIC. C'è però un punto su cui la selezione automatica, da sola, è muta: l'EDA grafica (Cap. 2.3) suggerisce che l'effetto di **bmi** possa dipendere da **smoker**, mentre le associazioni marginali, da sole, non sono sufficienti per chiudere la scelta del modello. L'ipotesi di **interazione** va quindi verificata esplicitamente nel capitolo seguente, confrontando modelli con e senza interazione.

Capitolo 4 — Modelli con predittori numerici e categorici

In questo capitolo esaminiamo in modo sistematico i modelli con **un predittore numerico e uno categorico**, confrontando per ciascuna coppia la versione senza interazione e quella con interazione. L'obiettivo è capire quali interazioni siano realmente utili, prima di costruire il modello multiplo.

La distinzione concettuale è la seguente:

- **senza interazione** ($y \sim \text{numerico} + \text{categorico}$): il predittore numerico ha la **stessa pendenza** in tutti i gruppi della variabile categorica; cambia solo l'**intercetta** fra i gruppi;
- **con interazione** ($y \sim \text{numerico} * \text{categorico}$): l'effetto (la pendenza) del predittore numerico **può cambiare** fra i livelli della categorica.

La stessa idea può essere scritta in forma esplicita. Se Z è un predittore numerico e G è una variabile indicatrice di gruppo, il modello senza interazione è

$$\mathbb{E}(Y \mid Z, G) = \beta_0 + \beta_1 Z + \beta_2 G.$$

Qui β_1 è la pendenza comune nei due gruppi. Il modello con interazione diventa invece

$$\mathbb{E}(Y \mid Z, G) = \beta_0 + \beta_1 Z + \beta_2 G + \beta_3 ZG.$$

In questo secondo caso la pendenza per il gruppo di riferimento è β_1 , mentre la pendenza per il gruppo $G = 1$ è $\beta_1 + \beta_3$. Il parametro β_3 misura quindi se l'effetto del predittore numerico cambia fra i gruppi. Questa è esattamente la domanda sostantiva che interessa per `age:smoker` e `bmi:smoker`.

4.1 e 4.2 Modelli senza e con interazione

Consideriamo i tre predittori numerici (`age`, `bmi`, `children`) incrociati con i tre categorici (`smoker`, `sex`, `region`). Per ogni coppia stimiamo entrambi i modelli e testiamo l'interazione con un confronto annidato (F -test).

```
combos <- expand.grid(num = c("age", "bmi", "children"),
                     cat = c("smoker", "sex", "region"),
                     stringsAsFactors = FALSE)
tab_nc <- do.call(rbind, lapply(seq_len(nrow(combos)), function(i) {
  nu <- combos$num[i]; ca <- combos$cat[i]
  m_a <- lm(as.formula(sprintf("sqrt_charges ~ %s + %s", nu, ca)), data = ins)
  m_i <- lm(as.formula(sprintf("sqrt_charges ~ %s * %s", nu, ca)), data = ins)
  p_int <- anova(m_a, m_i)$Pr(>F)[2]
  data.frame(Combinazione = sprintf("%s * %s", nu, ca),
             R2_adj_senza = round(summary(m_a)$adj.r.squared, 3),
             R2_adj_interazione = round(summary(m_i)$adj.r.squared, 3),
             p_interazione = formatC(p_int, format = "e", digits = 1),
             Signif = sig_stars(p_int))
}))
knitr::kable(tab_nc, row.names = FALSE,
             caption = "Modelli numerico x categorico: R2 aggiustato senza/con interazione e
  ↪ p-value del termine di interazione. Stelle: *** p<0.001, ** p<0.01, * p<0.05,
  ↪ . p<0.1.")
```

Tabella 6: Modelli numerico x categorico: R^2 aggiustato senza/con interazione e p-value del termine di interazione. Stelle: *** $p < 0.001$, ** $p < 0.01$, * $p < 0.05$, . $p < 0.1$.

Combinazione	$R^2_{\text{adj_senza}}$	$R^2_{\text{adj_interazione}}$	$p_{\text{interazione}}$	Signif
age * smoker	0.756	0.763	1.3e-10	***
bmi * smoker	0.598	0.637	8.7e-32	***
children * smoker	0.581	0.582	4.4e-02	*
age * sex	0.169	0.169	8.5e-01	
bmi * sex	0.028	0.029	6.5e-02	.
children * sex	0.011	0.011	8.0e-01	
age * region	0.171	0.171	5.1e-01	
bmi * region	0.028	0.029	3.4e-01	
children * region	0.014	0.013	4.4e-01	

4.3 Confronto tra modelli con e senza interazione

Per ogni coppia la tabella riporta due informazioni complementari: l' R^2 aggiustato senza e con interazione — di quanto migliora *davvero* l'adattamento, già penalizzato per il parametro in più — e il **p-value** del termine di interazione, cioè se quel miglioramento è statisticamente significativo. Qui l' R^2 aggiustato è la scelta corretta (e non l' R^2 semplice usato al Cap. 3.1): stiamo confrontando un modello più piccolo con uno più grande, e l' R^2 semplice crescerebbe comunque per il solo fatto di aggiungere un termine; l' R^2 aggiustato, penalizzando i parametri, dice invece se l'interazione vale il suo costo.

La tabella mostra un risultato molto chiaro: **le interazioni significative sono quelle con smoker**. In particolare **bmi * smoker** ($p \approx 10^{-32}$) e **age * smoker** ($p \approx 10^{-10}$) sono entrambe fortemente significative; anche **children * smoker** raggiunge la significatività, ma di stretta misura ($p \approx 0.04$) e con un guadagno isolato molto piccolo: è un caso particolare, che discutiamo a parte in 4.5. Tutte le interazioni con **sex** e con **region**, invece, **non sono significative**: nessuna raggiunge la soglia di 0.05, e l'unica che la sfiora (**bmi*sex**, segnata con un punto . nella tabella) resta comunque sopra 0.05 con un guadagno di adattamento trascurabile. Per questi fattori la versione senza interazione è adeguata, cioè l'effetto dei predittori numerici non cambia in modo apprezzabile fra i loro livelli.

4.4 Discussione delle combinazioni più informative

Le due interazioni più informative meritano un commento, anche grafico. Un'avvertenza sui grafici che seguono: a differenza degli scatterplot del Cap. 2.3 — disegnati sulla scala originale **charges** — qui l'asse verticale è $\sqrt{\text{charges}}$, cioè la scala su cui lavora il modello. È per questo che la nuvola di punti assume una forma diversa: sulla scala radice lo stacco di livello

fra fumatori e non fumatori si comprime, e diventa leggibile ciò che davvero ci interessa, la **differenza di pendenza** fra i due gruppi (l'interazione).

```
ggplot(ins, aes(age, sqrt_charges, color = smoker)) +  
  geom_point(alpha = 0.3) +  
  geom_smooth(method = "lm", se = FALSE) +  
  scale_color_manual(values = smoker_cols) +  
  labs(title = "age x smoker", y = "sqrt(charges)") +  
  theme_minimal()
```




Figura 27: Rette di regressione per smoker (age): le pendenze differiscono, la retta dei fumatori è più piatta.

```
ggplot(ins, aes(bmi, sqrt_charges, color = smoker)) +  
  geom_point(alpha = 0.3) +  
  geom_smooth(method = "lm", se = FALSE) +  
  scale_color_manual(values = smoker_cols) +  
  labs(title = "bmi x smoker", y = "sqrt(charges)") +  
  theme_minimal()
```




Figura 28: Rette di regressione per smoker (bmi): pendenza quasi nulla per i non fumatori, ripida per i fumatori.

- **bmi * smoker**: è l'interazione attesa da EDA e teoria. Per i non fumatori la pendenza del BMI è quasi nulla; per i fumatori è marcatamente positiva. Obesità e fumo agiscono in modo sinergico sul costo.
- **age * smoker**: qui l'analisi formale corregge l'impressione visiva del Capitolo 2. A occhio le rette di **age** sembravano vicine, ma il test rivela che le pendenze differiscono in modo significativo: la retta dei fumatori è più **piatta**. Una lettura plausibile è che, fra i fumatori, il costo è già elevato e cresce meno con l'età, mentre fra i non fumatori l'età resta il principale motore di crescita del costo. È un buon esempio del perché conviene **verificare** le interazioni invece di fidarsi solo del grafico.

4.5 Scelta delle interazioni eventualmente da mantenere

Sulla base di questa analisi, le interazioni candidate per il modello multiplo sono **bmi:smoker** e **age:smoker**: entrambe fortemente significative, interpretabili e con un guadagno apprezzabile nel modello completo (Cap. 5). Tutte le interazioni con **sex** e **region** vengono escluse perché non significative.

Il caso di **children:smoker** merita un discorso a parte, perché è il più delicato. Presa da sola (tabella sopra) è significativa solo di stretta misura ($p \approx 0.04$) e con un guadagno minimo: aggiunge appena $\approx 0.1\%$ di R^2 aggiustato, contro l' $\approx 3.9\%$ di **bmi:smoker** e lo $\approx 0.7\%$ di **age:smoker**. C'è però un punto da dire con onestà: se la si inserisce nel modello completo,

l'adattamento **migliora** comunque (R^2 aggiustato da 0.834 a 0.835) e l' F -test sul termine resta significativo ($p \approx 0.003$). Non la escludiamo quindi perché “non migliora i numeri” — li migliora, e con lo stesso criterio di adattamento che altrove ci porta a *tenere region* (Cap. 5.5) qui ci porterebbe ad *aggiungerla*.

La escludiamo per una ragione diversa, **interpretativa**. Per **age** e **bmi** esiste un meccanismo chiaro che rende sensata una pendenza diversa fra fumatori e non fumatori: età e obesità pesano di più quando si fuma. Per il numero di figli quel meccanismo non c'è — non si vede perché *avere figli* dovrebbe incidere sul costo in modo diverso a seconda che si fumi o no. Coerentemente con il principio guida del lavoro (un modello deve raccontare il fenomeno, non solo vincere su un criterio numerico), preferiamo tenere **children** come **solo effetto principale**, dove resta molto significativo, ed evitare un'interazione difficile da spiegare. La decisione definitiva sull'inclusione sarà comunque ripresa nel Capitolo 5, confrontando i modelli completi.

Capitolo 5 — Modello multiplo

Costruiamo ora il modello multiplo, procedendo dal modello additivo e aggiungendo le interazioni solo se motivate dai capitoli precedenti e dal confronto fra modelli. Il modello finale dovrà soddisfare tre condizioni: buon adattamento, interpretabilità dei coefficienti e coerenza con l'evidenza esplorativa. Non basta che una specifica migliori un criterio numerico; deve anche raccontare in modo plausibile la struttura del fenomeno osservato.

5.1 Modello additivo

Partiamo dal modello additivo suggerito dalla selezione del Capitolo 3.

```
m_add <- lm(sqrt_charges ~ age + sex + bmi + children + smoker + region, data = ins)
summary(m_add)
```

Call:

```
lm(formula = sqrt_charges ~ age + sex + bmi + children + smoker +
    region, data = ins)
```

Residuals:

Min	1Q	Median	3Q	Max
-41.024	-10.930	-4.763	3.096	106.158

Coefficients:

Estimate	Std. Error	t value	Pr(> t)
----------	------------	---------	----------

```

(Intercept)    0.64352    3.66591    0.176 0.860682
age            1.39833    0.04416   31.666 < 2e-16 ***
sexmale       -1.91234    1.23560   -1.548 0.121932
bmi           1.02996    0.10614    9.704 < 2e-16 ***
children      3.27427    0.51141    6.402 2.12e-10 ***
smokeryes     90.87174    1.53326   59.267 < 2e-16 ***
regionnorthwest -2.37668    1.76751   -1.345 0.178969
regionsoutheast -5.89446    1.77648   -3.318 0.000931 ***
regionsouthwest -5.20143    1.77366   -2.933 0.003419 **
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```

Residual standard error: 22.5 on 1329 degrees of freedom
Multiple R-squared: 0.7795, Adjusted R-squared: 0.7782
F-statistic: 587.4 on 8 and 1329 DF, p-value: < 2.2e-16

```

# Diagnostica di multicollinearità.
vt <- car::vif(m_add)
# VIF per i predittori numerici (a 1 grado di libertà il GVIF coincide col VIF classico).
knitr::kable(data.frame(VIF = round(vt[c("age", "bmi", "children"), "GVIF"], 2)),
  caption = "VIF dei predittori numerici.")

```

Tabella 7: VIF dei predittori numerici.

	VIF
age	1.02
bmi	1.11
children	1.00

```

# GVIF per i predittori categorici (region ha piu' di un grado di liberta').
knitr::kable(data.frame(GVIF = round(vt[c("sex", "smoker", "region"), "GVIF"], 2)),
  caption = "GVIF dei predittori categorici.")

```

Tabella 8: GVIF dei predittori categorici.

	GVIF
sex	1.01
smoker	1.01
region	1.10

Il modello additivo raggiunge un R^2 aggiustato ≈ 0.778 . Per la **multicollinearità** riportiamo il **VIF** per i predittori numerici e il **GVIF** (VIF generalizzato) per quelli categorici: il VIF

classico non è infatti definito su un fattore a più livelli come **region**, dove si usa la sua versione generalizzata. Tutti i valori sono prossimi a 1, ben lontani dalle soglie d'allarme (5–10): non vi è multicollinearità problematica, e le stime dei coefficienti sono numericamente stabili. Questo modello rappresenta una base utile, ma impone un vincolo forte: l'effetto di **age** e **bmi** deve essere lo stesso per fumatori e non fumatori. Le evidenze del Capitolo 4 suggeriscono che questo vincolo sia troppo rigido.

5.2 Modello con interazioni motivate

Aggiungiamo al modello additivo le due interazioni selezionate nel Capitolo 4 (**age:smoker** e **bmi:smoker**).

```
m_fin <- lm(sqrt_charges ~ sex + children + region + age*smoker + bmi*smoker, data = ins)

# Stime OLS del modello finale con entrambe le interazioni: coefficienti, errori
# standard, t-value e p-value (simmetrico al summary del modello additivo in 5.1).
summary(m_fin)
```

Call:

```
lm(formula = sqrt_charges ~ sex + children + region + age * smoker +
    bmi * smoker, data = ins)
```

Residuals:

Min	1Q	Median	3Q	Max
-42.762	-7.497	-5.863	-3.171	114.350

Coefficients:

	Estimate	Std. Error	t value	Pr(> t)
(Intercept)	22.63176	3.52595	6.419	1.91e-10 ***
sexmale	-2.90959	1.07067	-2.718	0.006663 **
children	3.47066	0.44271	7.840	9.22e-15 ***
regionnorthwest	-2.86933	1.53011	-1.875	0.060979 .
regionsoutheast	-5.92675	1.53844	-3.852	0.000123 ***
regionsouthwest	-6.30622	1.53594	-4.106	4.28e-05 ***
age	1.59135	0.04283	37.159	< 2e-16 ***
smokeryes	-4.43963	7.35337	-0.604	0.546110
bmi	0.08676	0.10304	0.842	0.399975
age:smokeryes	-0.85771	0.09513	-9.016	< 2e-16 ***
smokeryes:bmi	4.18766	0.21207	19.747	< 2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 19.47 on 1327 degrees of freedom
Multiple R-squared: 0.8351, Adjusted R-squared: 0.8339
F-statistic: 672.2 on 10 and 1327 DF, p-value: < 2.2e-16

Il modello con le due interazioni, `m_fin`, è la nostra specifica di riferimento:

`sqrt_charges ~ sex + children + region + age * smoker + bmi * smoker.`

La formula compatta con l'asterisco indica che, per ciascuna coppia, sono inclusi sia gli effetti principali sia il termine di interazione. In questo modo il modello consente a età e BMI di avere pendenze diverse nei due gruppi di fumo, senza introdurre interazioni non motivate con `sex` o `region`.

5.3 Confronto tra modelli

```
modelli <- list("Additivo" = m_add, "Con interazioni (finale)" = m_fin)
tab_cmp <- do.call(rbind, lapply(names(modelli), function(nm) {
  x <- modelli[[nm]]
  data.frame(Modello = nm,
             adjR2 = round(summary(x)$adj.r.squared, 4))
}))
knitr::kable(tab_cmp, row.names = FALSE,
             caption = "Confronto fra modello additivo e modello con interazioni.")
```

Tabella 9: Confronto fra modello additivo e modello con interazioni.

Modello	adjR2
Additivo	0.7782
Con interazioni (finale)	0.8339

Il guadagno è sostanziale: l' R^2 aggiustato passa da 0.778 (additivo) a 0.834 (con entrambe le interazioni), nonostante la penalizzazione per i parametri aggiunti. L' R^2 aggiustato va letto come **confronto relativo** fra modelli sugli stessi dati: orienta la scelta, ma non dimostra da solo che le ipotesi del modello siano soddisfatte (verificate con la diagnostica del Cap. 6). Le due interazioni, dunque, non sono raffinamenti marginali ma componenti importanti del modello.

5.4 Confronto ANOVA tra modelli annidati

Dopo aver confrontato l'adattamento dei modelli, usiamo l'ANOVA come confronto formale tra modelli annidati: modello additivo contro modello finale con entrambe le interazioni. Questo test appartiene alla fase di scelta della specifica, non alla diagnostica dei residui.

```
# Confronto annidato: additivo -> modello finale con entrambe le interazioni.
anova(m_add, m_fin)
```

Analysis of Variance Table

Model 1: sqrt_charges ~ age + sex + bmi + children + smoker + region

Model 2: sqrt_charges ~ sex + children + region + age * smoker + bmi *
smoker

	Res.Df	RSS	Df	Sum of Sq	F	Pr(>F)
1	1329	672636				
2	1327	503003	2	169633	223.76	< 2.2e-16 ***

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Il confronto è fortemente significativo ($p < 2.2 \times 10^{-16}$, $F \approx 224$): l'ANOVA supporta l'inserimento delle interazioni perché il miglioramento del modello è statisticamente rilevante. La lettura resta coerente con il percorso seguito finora: le interazioni `bmi:smoker` e `age:smoker` non vengono aggiunte perché suggerite automaticamente da un singolo criterio, ma perché migliorano il modello e hanno un'interpretazione sostanziale nel problema delle spese mediche.

5.5 Verifica sull'utilità di region

Verifichiamo infine una scelta rimasta aperta: l'utilità di `region`.

```
m_noreg <- lm(sqrt_charges ~ sex + children + age*smoker + bmi*smoker, data = ins)
knitr::kable(
  data.frame(
    Modello = c("modello finale", "senza region"),
    adjR2 = round(c(summary(m_fin)$adj.r.squared, summary(m_noreg)$adj.r.squared), 4),
    row.names = FALSE,
    caption = "Adattamento del modello finale con e senza region.")
```

Tabella 10: Adattamento del modello finale con e senza region.

Modello	adjR2
modello finale	0.8339
senza region	0.8316

Rimuovere **region** peggiora l'adattamento (l' R^2 aggiustato scende da 0.834 a 0.832): pur essendo marginalmente debole — al punto che il BIC la escludeva (Cap. 3) — nel modello completo i suoi coefficienti **southeast** e **southwest** restano significativi (vedi 5.6). È un caso in cui un predittore poco informativo *da solo* diventa utile *a parità di altri*: la **manteniamo**.

5.6 Interpretazione dei coefficienti

Riprendiamo la tabella dei coefficienti di **m_fin** stimata nel Cap. 5.2. Sulla scala radice i coefficienti **non** sono variazioni percentuali: un coefficiente β indica la variazione attesa di $\sqrt{\text{charges}}$ per un incremento unitario del predittore, a parità delle altre covariate. Per riportare l'effetto in modo approssimato alla scala in dollari si usa $\Delta \text{charges} \approx 2\sqrt{\text{charges}} \cdot \hat{\beta}$, quindi lo stesso coefficiente corrisponde a più dollari quando il costo di partenza è alto.

La presenza delle interazioni con **smoker** impone però una lettura separata per fumatori e non fumatori. La parte del modello che riguarda età e BMI può essere schematizzata così:

$$\beta_{\text{age}} \text{age} + \beta_{\text{bmi}} \text{bmi} + \beta_{\text{smoker}} \text{smoker} + \beta_{\text{age:smoker}} (\text{age} \cdot \text{smoker}) + \beta_{\text{bmi:smoker}} (\text{bmi} \cdot \text{smoker}).$$

Per i non fumatori (**smoker** = **no**) i termini di interazione valgono zero; per i fumatori le pendenze diventano la somma dell'effetto principale e dell'interazione. Da qui deriva l'interpretazione corretta:

- **age** — non fumatori: $\hat{\beta}_{\text{age}} \approx 1.59$, cioè +1.59 unità di $\sqrt{\text{charges}}$ per anno. Fumatori: la pendenza è $1.59 + (-0.86) \approx 0.73$, quindi la crescita con l'età è più **piatta**.
- **bmi** — non fumatori: $\hat{\beta}_{\text{bmi}} \approx 0.09$, non significativo (effetto trascurabile). Fumatori: $0.09 + 4.19 \approx 4.27$, cioè un incremento molto forte della radice della spesa per ogni unità di BMI.
- **children**: ≈ 3.47 , ogni figlio in più si associa a +3.47 unità di $\sqrt{\text{charges}}$.
- **sex**: i maschi hanno $\sqrt{\text{charges}}$ inferiore di circa 2.91 unità rispetto alle femmine, a parità di tutto il resto.
- **region**: rispetto a **northeast**, **southeast** e **southwest** hanno $\sqrt{\text{charges}}$ inferiore di circa 5.93 e 6.31 unità; **northwest** è solo borderline.

Per dare un ordine di grandezza in dollari, a un livello di costo di circa 10.000 USD ($\sqrt{\text{charges}} \approx 100$) il coefficiente di **age** per i non fumatori vale circa $2 \cdot 100 \cdot 1.59 \approx 318$ USD per anno, contro circa $2 \cdot 100 \cdot 0.73 \approx 147$ USD per anno per i fumatori; allo stesso livello, un'unità di BMI fra i fumatori vale circa $2 \cdot 100 \cdot 4.27 \approx 854$ USD. Sono conversioni locali, non effetti costanti in dollari su tutta la scala.

Gli effetti principali di **bmi** e **smoker** *isolati* non vanno interpretati come effetti “medi”: in presenza di interazione rappresentano l'effetto al valore zero dell'altra variabile (es. **smokeryes** è il differenziale a **age** = 0 e **bmi** = 0, fuori dal supporto dei dati). Una possibile alternativa sarebbe centrare **age** e **bmi**, così da leggere **smokeryes** alla media di età e BMI; qui manteniamo le variabili originali per non cambiare la specifica già discussa, ma interpretiamo sempre gli effetti per gruppo. Questo passaggio è importante perché evita una lettura meccanica della tabella dei coefficienti: il modello non dice soltanto che il fumo aumenta i costi, ma suggerisce che modifica anche il modo in cui età e BMI si legano alla spesa.

5.7 Valutazione della bontà di adattamento

Il modello **m_fin** spiega circa l'**83%** della varianza di **sqrt_charges** (R^2 aggiustato 0.834), con coefficienti interpretabili e VIF bassi. È un buon adattamento per dati individuali di questo tipo. Restano però da verificare le ipotesi su cui poggia l'inferenza (normalità, omoschedasticità): è l'oggetto del Capitolo 6.

Il grafico seguente visualizza il modello multiplo finale confrontando valori osservati e valori stimati. In una regressione multipla non esiste un solo predittore da mettere sull'asse x; per questo il confronto più diretto è **sqrt(charges)** osservato contro **sqrt(charges)** predetto dal modello. La linea diagonale rappresenta la previsione perfetta.

```
ins_pred <- ins %>%
  mutate(pred_sqrt = fitted(m_fin))

ggplot(ins_pred, aes(x = pred_sqrt, y = sqrt_charges, color = smoker)) +
  geom_point(alpha = 0.45) +
  geom_abline(intercept = 0, slope = 1, color = "#1D3557", linewidth = 0.9) +
  scale_color_manual(values = smoker_cols) +
  labs(title = "Modello finale: osservati vs predetti",
       x = "Valori predetti dal modello",
       y = "Valori osservati: sqrt(charges)") +
  theme_minimal()
```




Figura 29: Modello multiplo finale: valori osservati e valori predetti su scala radice.

Capitolo 6 — Diagnostica dei residui ed eteroschedasticità

Nel Capitolo 5 abbiamo scelto il modello finale e interpretato i coefficienti. Prima di usarli come base inferenziale controlliamo però come si comportano i residui. La domanda pratica è semplice: il modello cattura la struttura principale delle spese mediche oppure lascia pattern che rendono meno affidabili p-value e intervalli di confidenza?

Nel modello lineare classico queste condizioni si riassumono così:

$$Y = X\beta + \varepsilon, \quad \mathbb{E}(\varepsilon \mid X) = 0, \quad \text{Var}(\varepsilon \mid X) = \sigma^2 I.$$

Nel nostro caso la parte più delicata riguarda la varianza degli errori: con costi sanitari molto asimmetrici e osservazioni estreme, è realistico aspettarsi una dispersione diversa tra individui a basso costo e individui ad alto costo. Per questo usiamo la diagnostica non come esercizio formale, ma per decidere come rendere più solida l'inferenza.

6.1 Diagnostica grafica dei residui

```
# Quattro grafici diagnostici del modello lineare finale.
plot(m_fin, which = 1) # Residuals vs Fitted
```




Figura 30: Residuals vs Fitted

```
plot(m_fin, which = 2) # Normal Q-Q
```




Figura 31: Normal Q-Q

```
plot(m_fin, which = 3) # Scale-Location
```




Figura 32: Scale-Location

```
plot(m_fin, which = 4) # Cook's distance
```




Figura 33: Cook's distance

La diagnostica mostra che il modello cattura bene la struttura principale dei dati, ma non elimina completamente alcuni problemi tipici di questo dataset. Nel pannello **Residuals vs Fitted** non emergono curvature sistematiche, quindi la specificazione della media appare ragionevole. Il **Q-Q plot** segnala invece code pesanti: i residui si allontanano dalla retta soprattutto agli estremi. Lo **Scale-Location** mostra una dispersione non costante, con residui più variabili al crescere dei valori predetti.

Il quarto pannello è il grafico della **Cook's distance** (`which = 4`) e serve a verificare se singole osservazioni influenzano in modo eccessivo la stima: nel complesso non emergono osservazioni estremamente influenti. Le criticità principali sono quindi normalità non perfetta ed eteroschedasticità residua, che verifichiamo nelle sezioni successive.

6.2 Test di normalità e limiti interpretativi

```
# Test sui residui studentizzati internamente (rstandard): rimuovono la varianza
# non costante artificiale dovuta alla leva (1 - h_ii), quindi sono l'oggetto
# corretto per valutare la normalità degli errori (coerente col Q-Q plot del 6.1).
shapiro.test(rstandard(m_fin))      # Shapiro-Wilk
```

Shapiro-Wilk normality test

```
data:  rstandard(m_fin)
W = 0.57928, p-value < 2.2e-16
```

```
moments::jarque.test(rstandard(m_fin)) # Jarque-Bera (basato su skewness e curtosi)
```

Jarque-Bera Normality Test

```
data:  rstandard(m_fin)
JB = 6077.2, p-value < 2.2e-16
alternative hypothesis: greater
```

Entrambi i test, applicati ai **residui studentizzati** (`rstandard`), indicano che i residui non seguono una distribuzione normale: Shapiro-Wilk restituisce $W \approx 0.58$ e Jarque-Bera una statistica molto elevata, in entrambi i casi con $p < 2.2 \times 10^{-16}$. Il risultato è coerente con il Q-Q plot: lo scostamento riguarda soprattutto le **code pesanti**, cioè la parte dei costi più difficili da descrivere con un modello lineare gaussiano.

Il risultato però non compromette l'inferenza, per due motivi. Primo: con un campione ampio ($n = 1338$) i test di normalità sono **molto sensibili** e rifiutano l'ipotesi anche per scostamenti modesti, di scarsa rilevanza pratica. Secondo, e più importante: per il **Teorema del Limite Centrale**, con n così grande lo stimatore dei minimi quadrati è approssimativamente normale anche con errori non gaussiani, quindi i test t e F sui coefficienti restano validi. La non-normalità qui riguarda le **code** — i costi estremi, che sono soggetti reali e non errori — e la affrontiamo dove conta, modellando la parte alta della spesa con la **Quantile Regression** del Capitolo 7.

6.3 Test di eteroschedasticità

```
lmtest::bptest(m_fin) # Breusch-Pagan; H0: omoschedasticità
```

studentized Breusch-Pagan test

```
data: m_fin  
BP = 19.619, df = 10, p-value = 0.03307
```

Il test di Breusch-Pagan ($BP \approx 19.6$, $p \approx 0.033$) indica eteroschedasticità residua, ma molto più lieve di quanto la scala originale lascerebbe temere: la significatività è **borderline**. In pratica, l'errore del modello è solo moderatamente più variabile in alcune aree della spesa attesa — un effetto della scala radice, che comprime meno dei valori alti ma stabilizza comunque bene la varianza. Questo non cambia i coefficienti stimati, ma invita comunque a non basare l'inferenza solo sugli errori standard classici, che assumono varianza costante.

6.4 Stima WLS: modello pesato per l'eteroschedasticità

Poiché la diagnostica indica eteroschedasticità residua, adottiamo come riferimento una stima **Weighted Least Squares** (WLS). L'idea è assegnare meno peso alle osservazioni nelle aree in cui la varianza degli errori è stimata più alta, e più peso alle osservazioni nelle aree più stabili. In forma matriciale, lo stimatore è

$$\hat{\beta}_{\text{WLS}} = (X'WX)^{-1}X'Wy,$$

dove W è una matrice diagonale di pesi. Idealmente, i pesi sono proporzionali all'inverso della varianza condizionata degli errori:

$$w_i \propto \frac{1}{\text{Var}(\varepsilon_i | X_i)}.$$

Nel nostro caso la struttura della varianza non è nota, quindi usiamo una procedura fattibile: stimiamo prima il modello OLS, modelliamo il logaritmo dei residui quadratici in funzione dei valori stimati, e poi usiamo l'inverso della varianza stimata come peso. In questo modo il modello finale mantiene la stessa specifica interpretativa del Capitolo 5, ma tiene conto della dispersione non costante emersa nella diagnostica.

```
# 1) Stimiamo la varianza degli errori: log(residui^2) sui valori predetti.
# Il log serve solo a garantire pesi positivi; la RISPOSTA del modello resta sqrt_charges.
res2 <- pmax(residuals(m_fin)^2, .Machine$double.eps)
w <- 1 / exp(fitted(lm(log(res2) ~ fitted(m_fin))))

# 2) Ristimiamo il modello finale (sempre su sqrt_charges) con i pesi WLS.
m_wls <- lm(sqrt_charges ~ sex + children + region + age*smoker + bmi*smoker,
            data = ins, weights = w)

knitr::kable(round(data.frame(
  OLS_coef = coef(m_fin),
  WLS_coef = coef(m_wls),
  SE_OLS   = summary(m_fin)$coefficients[, 2],
  SE_WLS   = summary(m_wls)$coefficients[, 2]), 4),
  caption = "Confronto tra OLS e WLS.")
```

Tabella 11: Confronto tra OLS e WLS.

	OLS_coef	WLS_coef	SE_OLS	SE_WLS
(Intercept)	22.6318	22.6796	3.5260	3.5104
sexmale	-2.9096	-2.9800	1.0707	1.0762
children	3.4707	3.5410	0.4427	0.4456
regionnorthwest	-2.8693	-2.9132	1.5301	1.5385
regionsoutheast	-5.9267	-5.9888	1.5384	1.5489
regionsouthwest	-6.3062	-6.4560	1.5359	1.5438
age	1.5914	1.5905	0.0428	0.0427
smokeryes	-4.4396	-5.2252	7.3534	7.5779
bmi	0.0868	0.0868	0.1030	0.1027
age:smokeryes	-0.8577	-0.8586	0.0951	0.0984
smokeryes:bmi	4.1877	4.2152	0.2121	0.2196

Il confronto va letto su due piani. I **coefficienti** WLS sono praticamente identici a quelli OLS: è un segnale di **robustezza** — la specifica del Capitolo 5 non era distorta dalla varianza non costante, e le conclusioni sostanziali non cambiano. Gli **errori standard** vengono invece ricalcolati dando meno peso alle osservazioni nelle zone a varianza più alta.

Resta però la domanda che conta: il WLS **ha davvero ridotto** l'eteroschedasticità? Per rispondere non bastano i residui ordinari, ma vanno ripetuti i test sui **residui pesati**, cioè sull'OLS applicato al modello trasformato $\sqrt{w}y \sim \sqrt{w}X$ (ciò che il WLS minimizza).

```
# Verifica: i test si applicano ai residui PESATI (OLS sul modello trasformato).
sw <- sqrt(w)
y_w <- sw * ins$sqrt_charges
X_w <- sw * model.matrix(m_fin)
m_wls_eq <- lm(y_w ~ 0 + X_w)

lmtest::bptest(m_wls_eq)          # eteroschedasticità dopo la correzione
```

studentized Breusch-Pagan test

```
data:  m_wls_eq
BP = 22.114, df = 10, p-value = 0.01453
```

```
shapiro.test(rstandard(m_wls_eq)) # normalità dopo la correzione
```

Shapiro-Wilk normality test

```
data:  rstandard(m_wls_eq)
W = 0.57241, p-value < 2.2e-16
```

Il risultato va riportato con onestà: dopo il WLS il Breusch-Pagan resta significativo ($BP \approx 22$, $p \approx 0.015$) e la non-normalità è invariata ($W \approx 0.57$). In altre parole, **il WLS non elimina l'eteroschedasticità** — anche se va ricordato che con un campione ampio ($n = 1338$) il Breusch-Pagan è molto sensibile e segnala come significativo anche uno scostamento modesto. La ragione di fondo è che la dispersione non cresce in modo regolare con i valori predetti — dipende soprattutto dalla separazione fra fumatori e non fumatori — e un peso costruito sui soli valori stimati non ne cattura la struttura. Poiché però l'eteroschedasticità è **lieve** e i coefficienti OLS e WLS coincidono, le conclusioni del Capitolo 5 restano valide. Manteniamo quindi il WLS come riferimento, segnalando con trasparenza che la correzione è parziale: la varianza residua riflette la struttura a due sotto-popolazioni (fumatori e non fumatori) più che una semplice crescita con i valori predetti. Resta comunque valido l'argomento già richiamato per la non-normalità (Cap. 6.2): con $n = 1338$, per il **Teorema del Limite Centrale** lo stimatore dei minimi quadrati converge a una distribuzione normale anche con errori non gaussiani e a varianza non costante, purché a varianza finita e osservazioni indipendenti. I test t e F restano quindi validi in senso **asintotico** — una garanzia di convergenza, non una certezza esatta: vale nella misura in cui queste condizioni teoriche sono effettivamente soddisfatte.

Capitolo 7 — Modelli alternativi

Il modello lineare del Capitolo 5 resta lo strumento principale: descrive l'effetto medio condizionato dei predittori su `sqrt_charges` e permette una lettura chiara dei coefficienti. In questo capitolo aggiungiamo la **Quantile Regression** per completare l'analisi: non vogliamo guardare solo al costo medio atteso, ma anche a cosa succede nella mediana, nel terzo quartile e nella coda alta della spesa.

7.1 Quantile Regression

La regressione quantile è particolarmente utile in un dataset come `insurance.csv`, dove la spesa medica è asimmetrica e pochi individui concentrano livelli di costo molto elevati. OLS sintetizza l'associazione media; la Quantile Regression stima invece l'effetto dei predittori in punti specifici della distribuzione, dal decimo percentile ($\tau = 0.10$) alla coda alta ($\tau = 0.90$), passando per i quartili e la mediana. In questo modo possiamo verificare se gli effetti osservati nel modello medio restano simili lungo tutta la distribuzione dei costi, dai più bassi ai più elevati.

Per completezza, per un quantile τ la stima risolve un problema di minimizzazione pesata degli scarti assoluti:

$$\hat{\beta}_\tau = \arg \min_{\beta} \sum_{i=1}^n \rho_\tau(y_i - x'_i \beta),$$

dove $\rho_\tau(u)$ pesa in modo diverso gli errori positivi e negativi. La formula serve solo a chiarire la domanda statistica: non stiamo sostituendo OLS con un altro modello “migliore”, ma stiamo osservando se le associazioni cambiano quando ci spostiamo dai costi tipici verso quelli più elevati. Il modello quantile include **gli stessi regressori** del modello finale (Cap. 5): ogni coefficiente è stimato a parità di tutti gli altri. La tabella e il grafico che seguono ne riportano solo i termini più rilevanti, per leggibilità, ma la stima li include tutti.

```
taus <- c(0.10, 0.25, 0.50, 0.75, 0.90)
qr <- quantreg::rq(sqrt_charges ~ sex + children + region + age*smoker + bmi*smoker,
  data = ins, tau = taus, method = "fn")

# Coefficienti dei termini chiave a ogni quantile, con l'OLS (Cap. 5) come riferimento.
key <- c("age", "age:smokeryes", "smokeryes:bmi", "children", "sexmale")
tab_qr <- rbind(round(t(coef(qr)[key, ]), 3),
  OLS = round(coef(m_fin)[key], 3))
knitr::kable(tab_qr,
  caption = "Coefficienti dei termini chiave ai vari quantili, confrontati con
  ↪ l'OLS.")
```

Tabella 12: Coefficienti dei termini chiave ai vari quantili, confrontati con l'OLS.

	age	age:smokeryes	smokeryes:bmi	children	sexmale
tau= 0.10	1.729	-0.837	3.636	3.036	-3.230
tau= 0.25	1.704	-0.803	4.054	3.244	-2.907
tau= 0.50	1.688	-1.028	4.609	3.317	-2.805
tau= 0.75	1.665	-0.989	4.705	3.507	-2.854
tau= 0.90	1.630	-1.075	3.509	4.159	-2.959
OLS	1.591	-0.858	4.188	3.471	-2.910

Prima di leggere i singoli coefficienti, una domanda preliminare: gli effetti **cambiano davvero** lungo la distribuzione, o le differenze fra quantili sono solo rumore? Lo verifichiamo con un test di uguaglianza delle pendenze fra quantili.

```
# H0: i coefficienti sono uguali a tutti i quantili (nessuna eterogeneità).
anova(quantreg::rq(sqrt_charges ~ sex + children + region + age*smoker + bmi*smoker,
  data = ins, tau = c(0.25, 0.50, 0.75)))
```

Quantile Regression Analysis of Deviance Table

Model: sqrt_charges ~ sex + children + region + age * smoker + bmi * smoker
 Joint Test of Equality of Slopes: tau in { 0.25 0.5 0.75 }

```
Df Resid Df F value    Pr(>F)
1 20      3994  14.658 < 2.2e-16 ***
```

Signif. codes: 0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

```
# Mostriamo i termini interpretabili e su scala comparabile (escluso smokeryes).
quantile_terms <- c("age", "children",
  "age:smokeryes", "smokeryes:age",
  "smokeryes:bmi", "bmi:smokeryes")

qr_plot <- as.data.frame(coef(qr)) %>%
  rownames_to_column("Termine") %>%
  filter(Termine %in% quantile_terms) %>%
  mutate(Termine = case_when(
    Termine %in% c("age:smokeryes", "smokeryes:age") ~ "age:smoker",
    Termine %in% c("smokeryes:bmi", "bmi:smokeryes") ~ "bmi:smoker",
    TRUE ~ Termine
  )) %>%
  pivot_longer(~Termine, names_to = "tau", values_to = "Coefficiente") %>%
  mutate(tau = readr::parse_number(tau))
```

```
# Coefficienti OLS (Cap. 5) come riferimento, stessa codifica dei termini.
ols_ref <- data.frame(
  Termine = c("age", "children", "age:smoker", "bmi:smoker"),
  ols      = coef(m_fin)[c("age", "children", "age:smoker", "smokeryes:bmi")]
)

ggplot(qr_plot, aes(x = tau, y = Coefficiente, color = Termine)) +
  geom_hline(data = ols_ref, aes(yintercept = ols, color = Termine),
            linetype = "dashed", linewidth = 0.5, alpha = 0.7) +
  geom_line(linewidth = 0.9) +
  geom_point(size = 2.4) +
  scale_color_manual(values = model_cols) +
  scale_x_continuous(breaks = taus) +
  labs(title = "Coefficienti quantili vs OLS (tratteggio)",
       x = "Quantile della risposta",
       y = "Coefficiente stimato") +
  theme_minimal()
```




Figura 34: Coefficienti quantili dei termini interpretabili, confrontati con l'OLS (linee tratteggiate). Escluso l'effetto principale smokeryes, non interpretabile da solo e su scala molto più ampia.

7.2 Confronto degli effetti sui diversi quantili

Il test è netto: l'uguaglianza delle pendenze fra i quantili è **rifiutata** ($F \approx 14.7$, $p < 2.2 \times 10^{-16}$). Gli effetti, quindi, **non sono costanti** lungo la distribuzione: guardare oltre la media è

statisticamente giustificato. Tutti i coefficienti chiave restano inoltre altamente significativi a ogni quantile. Il confronto con l'OLS (linee tratteggiate nel grafico) mostra dove si concentrano le differenze:

- **age** (non fumatori): stabile e molto vicino all'OLS, da ≈ 1.73 ($\tau = 0.10$) a ≈ 1.63 ($\tau = 0.90$).
- **age:smoker**: negativa a tutti i quantili (da ≈ -0.84 a ≈ -1.08): la crescita della spesa con l'età è sistematicamente più piatta per i fumatori.
- **bmi:smoker**: forte ovunque, con un massimo intorno al terzo quartile (≈ 4.7) e un calo nella coda estrema (≈ 3.5 a $\tau = 0.90$): il peso dell'obesità fra i fumatori è massimo sui costi medio-alti.
- **children**: è il pattern più netto: **cresce** dal decimo percentile (≈ 3.0) alla coda alta (≈ 4.2), segno che ogni figlio in più pesa di più per gli individui già costosi.

La Quantile Regression, quindi, non sostituisce il modello lineare ma lo **completa**: il test conferma che gli effetti variano lungo la distribuzione di `sqrt_charges`, e i pattern di `children` e `bmi:smoker` mostrano *dove*. In ottica assicurativa questo conta, perché la coda dei costi elevati pesa molto sulla spesa complessiva.

Capitolo 8 — Conclusioni

8.1 Sintesi dei risultati principali

Il lavoro ha costruito, in modo graduale, un modello per la spesa sanitaria individuale, distinguendo due obiettivi: esplorativo e inferenziale. La logica seguita è stata cumulativa: ogni capitolo ha ristretto lo spazio delle scelte plausibili, senza trasformare un singolo indice numerico in una decisione automatica.

Sul piano **esplorativo**, l'analisi ha documentato un dataset Kaggle completo (1338 osservazioni, nessun valore mancante), una risposta fortemente asimmetrica — da cui la scelta, *a vista*, della scala radice — e relazioni bivariate utili a formulare ipotesi di lavoro. Sul piano **inferenziale**, la costruzione progressiva (regressioni semplici $\rightarrow$ selezione $\rightarrow$ modelli numerico-categorici $\rightarrow$ modello multiplo $\rightarrow$ ANOVA tra modelli annidati) ha portato a un modello con due interazioni motivate, `bmi:smoker` e `age:smoker`, con R^2 aggiustato ≈ 0.83 . La diagnostica ha rilevato residui non perfettamente normali e una lieve eteroschedasticità (solo borderline); per questo la lettura finale usa una stima WLS. La regressione quantile completa il quadro mostrando che le interazioni con `smoker`, in particolare `bmi:smoker`, restano rilevanti lungo tutta la distribuzione dei costi.

8.2 Scelta finale del modello

Lo strumento principale è il **modello lineare**

$$\text{sqrt_charges} \sim \text{sex} + \text{children} + \text{region} + \text{age} * \text{smoker} + \text{bmi} * \text{smoker},$$

stimato con pesi WLS. La scelta privilegia l'equilibrio fra adattamento, gestione dell'eteroschedasticità e **fedeltà ai costi elevati**: la scala radice attenua l'asimmetria senza comprimere troppo la coda alta, e i suoi coefficienti — espressi in unità di $\sqrt{\text{charges}}$ — restano traducibili in dollari a un dato livello di costo. In particolare, il modello suggerisce che il fumo non agisca solo come differenza di livello, ma modifichi anche la relazione del costo con età e BMI. La **Quantile Regression** resta un complemento prezioso: conferma che non tutti gli effetti sono uguali lungo la distribuzione e aiuta a leggere la coda alta dei costi.

8.3 Limiti dell'analisi

I risultati vanno letti con alcune cautele. I dati sono **osservazionali** e trasversali: le associazioni stimate non sono effetti causali. Il vettore di predittori è **ridotto** (sei variabili demografiche e comportamentali) ed esclude la storia clinica, le abitudini alimentari e l'attività fisica: l'effetto di **smoker** incorpora verosimilmente quote di rischio correlate non osservate. La **specificazione** è lineare con due interazioni; la non-normalità residua segnala una sotto-popolazione di costi estremi non pienamente catturata. Infine, i dati sono statunitensi e non direttamente trasferibili ad altri sistemi sanitari.

Queste cautele non annullano il risultato, ma ne definiscono correttamente il perimetro: il modello è adatto a descrivere associazioni condizionate e a produrre un'inferenza prudente sui coefficienti, non a stabilire relazioni causali né a fornire una regola predittiva universale.